

PRD Scrapebot: Akuisisi Data Mentah

Dokumen kebutuhan produk untuk pengumpulan data mentah dari situs web calon mitra ritel

Tanggal	5 Oktober 2026
Status	Draf untuk ditinjau
Pemilik	Tim Wooden Ships Knits
Batas cakupan	Dari daftar toko masuk sampai data mentah tersimpan
Dokumen terkait	rancangan-scrapebot-v2.pdf, alur-kerja-teknis-scrapebot.pdf

Ringkasan satu paragraf. Scrapebot mengunjungi situs web setiap toko dalam daftar calon mitra dan menyimpan semua data produk dan halaman yang dapat dibacanya, **apa adanya**, lengkap dengan asal data dan statusnya. Toko Shopify, WooCommerce, Squarespace, situs JavaScript, dan situs tanpa data terstruktur semuanya ditangani dengan cara termurah yang berhasil. Format masukan dan keluaran tidak terikat pada CSV: keduanya dipilih lewat konfigurasi. Pengolahan lanjutan, seperti normalisasi harga, validasi kualitas, dan penilaian rajutan, **tidak termasuk** dalam PRD ini.

Daftar isi

1. Latar belakang dan masalah
2. Tujuan dan metrik keberhasilan
3. Pengguna
4. Ruang lingkup
5. Alur sistem
6. Kebutuhan fungsional
7. Spesifikasi data mentah
8. Kebutuhan nonfungsional
9. Rencana rilis
10. Asumsi dan dependensi
11. Risiko dan mitigasi
12. Pertanyaan terbuka
13. Glosarium

1. Latar Belakang dan Masalah

Versi 1 Scrapebot sudah membaca toko Shopify dengan tepat melalui umpan `/products.json`. Survei awal pada 67 domain di Naples, Florida, menghasilkan 6.167 produk berharga dari 26 toko Shopify. Namun, 41 toko lainnya memakai platform lain, dan versi 1 hanya membacanya melalui JSON-LD.

Masalah yang ingin diselesaikan:

1. **Data toko non-Shopify hilang.** Toko tanpa JSON-LD menghasilkan nol produk, padahal katalognya ada.
2. **Nol produk tidak dapat dibedakan.** Keluaran tidak membedakan antara “toko tidak punya katalog” dan “katalog tidak terbaca”.
3. **Harga tanpa mata uang.** Harga yang dilokalkan ke mata uang lain dapat masuk tanpa terdeteksi.
4. **Data mentah tidak lengkap.** Versi 1 hanya menyimpan 5.000 karakter teks per halaman, sehingga pengolahan ulang di kemudian hari terbatas.

Pemblokiran bukan masalah utama: dari 67 domain, tidak ada calon mitra yang hilang karena deteksi bot. Yang kurang adalah cakupan pembacaan.

2. Tujuan dan Metrik Keberhasilan

2.1 Tujuan

1. Mengumpulkan data produk mentah (judul, harga, mata uang, URL) dari toko Shopify **dan** non-Shopify tanpa menulis selektor khusus per situs.
2. Menyimpan semua yang terkumpul secara lengkap, sehingga pengolahan berikutnya tidak pernah memerlukan scraping ulang.
3. Membuat setiap data dapat ditelusuri asalnya: tahap, URL bukti, dan waktu pengambilan.
4. Mengeluarkan biaya peramban dan LLM hanya untuk toko yang memerlukannya.

2.2 Metrik keberhasilan

Metrik bertanda **mutlak** wajib dipenuhi untuk rilis. Metrik bertanda **usulan** akan dikonfirmasi setelah survei dan benchmark pada Tahap 1.

Metrik	Target	Jenis
Baris masukan yang memiliki entri di indeks keluaran	100%	Mutlak
Toko berstatus <code>ok</code> dengan nol produk	0	Mutlak
Produk yang menyertakan tahap sumber dan URL bukti	100%	Mutlak
Permintaan yang melanggar <code>robots.txt</code> atau menembus tantangan	0	Mutlak
Toko non-Shopify yang menghasilkan minimal satu produk mentah	$\geq 60\%$	Usulan
Toko berproduk yang mata uangnya terdeteksi	$\geq 95\%$	Usulan
Ketepatan produk hasil LLM pada gold set	$\geq 90\%$	Usulan
Durasi satu run ± 70 domain tanpa peramban dan LLM	≤ 30 menit	Usulan
Biaya LLM per run	$\leq$ batas di konfigurasi	Mutlak

3. Pengguna

Pengguna	Kebutuhan	Cara memakai
Operator bot	Menjalankan bot pada daftar toko dan tahu hasilnya dalam satu laporan	Menjalankan perintah CLI, membaca laporan run, memeriksa status per toko
Pengolah data (tahap berikutnya)	Data mentah yang lengkap, konsisten, dan dapat ditelusuri asalnya	Membaca JSON mentah dan indeks untuk normalisasi, validasi, dan penilaian
Peninjau	Tahu data mana yang perlu diperiksa manusia	Menyaring entri dengan <code>needs_review</code> dan status <code>no_products</code>

4. Ruang Lingkup

4.1 Dalam cakupan


- Membaca daftar toko dari berbagai format melalui adapter masukan (JSON, JSONL, daftar URL, argumen CLI, CSV), menormalkan URL, dan menggabungkan domain ganda.
- Mengambil halaman secara sopan: `robots.txt`, jeda per domain, cache, dan coba ulang.
- Mendeteksi platform dan mata uang setiap toko.
- Membaca umpan produk platform: Shopify, WooCommerce, Squarespace, dan Lightspeed (bila terverifikasi).
- Menemukan halaman melalui sitemap dan tautan, lalu mengambil halaman produk, kontak, “tentang kami”, dan grosir.
- Membaca data terstruktur: JSON-LD, Microdata, OpenGraph, RDFa, dan state aplikasi.
- Render peramban dan penangkapan XHR JSON untuk situs JavaScript (bersyarat).
- Ekstraksi LLM untuk toko yang masih nol produk (bersyarat).
- Menyimpan data mentah per toko, HTML halaman, indeks keluaran, dan laporan run, dengan format keluaran yang dipilih lewat adapter keluaran.
- Konfigurasi plug-in untuk memilih pustaka setiap tahap.

4.2 Di luar cakupan

Hal	Keterangan
Normalisasi data	Konversi harga ke desimal, kode mata uang ISO, penggabungan produk ganda. Dikerjakan pada tahap berikutnya dari data mentah
Validasi kualitas	Menolak produk tidak wajar. Data mentah disimpan apa adanya; satu-satunya penyaringan adalah aturan bukti untuk hasil LLM
Sinyal toko	Penghitungan rajutan, rentang harga, ekstraksi kontak terstruktur, penanda jaringan ritel
CSV diperkaya v1	Fitur v1 ini tetap berjalan seperti sekarang, tetapi tidak dikembangkan dalam PRD ini
Penilaian calon mitra	Bot mengumpulkan, manusia memutuskan
Menembus antibiot	Tidak ada penyelesaian CAPTCHA atau tantangan, tanpa rotasi proksi, <code>robots.txt</code> selalu dipatuhi
Login	Hanya halaman publik
Mencari toko baru	Daftar masukan tetap dari Google Places
Penjangkauan dan CRM	Pengiriman surel atau integrasi CRM
API dan dasbor	Bot menulis data; menyajikannya lewat API atau dasbor adalah proyek terpisah. Penulisan ke SQLite atau PostgreSQL tersedia sebagai adapter keluaran

5. Alur Sistem

Setiap toko berhenti pada tahap pertama yang menghasilkan produk. Apa pun hasilnya, setiap toko tetap disimpan dengan statusnya. Batas cakupan PRD ini ada di kotak “Simpan”.



Gambar 1. Alur sistem dan batas cakupan. Kotak abu-abu bergaris putus-putus adalah pengolahan lanjutan yang berada di luar PRD ini.

6. Kebutuhan Fungsional

Prioritas: **Wajib** harus ada untuk rilis; **Bersyarat** hanya dibangun bila survei Tahap 1 membenarkannya (minimal 5 situs calon mitra yang membutuhkannya); **Sebaiknya** dikerjakan bila waktu memungkinkan.

6.1 Masukan dan pengambilan

ID	Kebutuhan	Prioritas	Kriteria penerimaan
FR-01	Membaca daftar toko melalui adapter masukan: JSON, JSONL, daftar URL (TXT), argumen CLI, dan CSV. Format dikenali dari ekstensi atau dipilih di konfigurasi	Wajib	Daftar yang sama dalam kelima format menghasilkan data mentah yang identik
FR-01a	Nama field URL dapat diatur (bawaan <code>website</code>); semua field lain diteruskan utuh sebagai objek <code>input</code> , berapa pun jumlah dan bentuknya	Wajib	Masukan tanpa field URL ditolak dengan pesan jelas; field bertingkat (JSON) tetap utuh di keluaran
FR-01b	Adapter masukan Google Sheets	Sebaiknya	Daftar dibaca langsung dari tautan sheet tanpa ekspor manual
FR-02	Menormalkan URL dan menggabungkan duplikat <code>www.</code>	Wajib	Dua baris dengan domain sama diambil sekali; keduanya tetap punya entri di indeks
FR-03	Baris tanpa situs atau hanya media sosial diberi status skip	Wajib	Status <code>no_website</code> atau <code>social_only</code> ; tidak ada permintaan jaringan untuk baris itu
FR-04	Pengambilan sopan: <code>robots.txt</code> , jeda 1,5 detik per domain, coba ulang bertahap	Wajib	Tes membuktikan URL yang dilarang tidak diambil dan jeda per domain dijaga
FR-05	Hanya respons berhasil yang disimpan di cache	Wajib	Run ulang mencoba lagi toko yang sebelumnya gagal karena batas waktu, 429, atau 5xx
FR-06	Header <code>Accept-Language</code> tidak dikirim	Wajib	Tes memastikan header tidak ada pada setiap permintaan HTTP
FR-07	Mendeteksi pemblokiran: 401, 403, 429, dan halaman tantangan Cloudflare	Wajib	Status <code>blocked</code> ; tidak ada upaya penembusan
FR-08	Sertifikat TLS rusak dicoba sekali tanpa verifikasi dan ditandai	Wajib	Status atau penanda <code>ssl_bypassed</code> tercatat

6.2 Profil dan umpan

ID	Kebutuhan	Prioritas	Kriteria penerimaan
FR-09	Mendeteksi platform dari penanda beranda	Wajib	Platform tercatat untuk setiap toko yang berandanya terbaca
FR-10	Mendeteksi mata uang beserta sumbernya	Wajib	Mata uang dan sumbernya (Shopify, JSON-LD, umpan) tercatat; kosong bila tidak ditemukan
FR-11	Membaca umpan Shopify <code>/products.json</code> berhalaman	Wajib	Sudah ada; respons umpan mentah ikut disimpan
FR-12	Membaca WooCommerce Store API	Wajib	Fixture dari situs nyata lulus tes; harga mentah dan <code>currency_minor_unit</code> disimpan apa adanya
FR-13	Membaca Squarespace <code>?format=json</code>	Wajib	Fixture kedua versi templat lulus tes
FR-14	Membaca Lightspeed eCom	Sebaiknya	Dikerjakan bila survei membuktikan endpoint-nya bekerja

6.3 Penemuan dan pengambilan halaman

ID	Kebutuhan	Prioritas	Kriteria penerimaan
FR-15	Membaca sitemap, termasuk indeks dan sitemap khusus produk	Wajib	Sitemap Wix, Yoast, dan WordPress terbaca dari fixture
FR-16	Menelusuri tautan internal bila tidak ada sitemap, hingga kedalaman 2	Wajib	Tes penelusuran pada fixture situs tanpa sitemap
FR-17	Antrean URL kanonik, tanpa duplikat, diprioritaskan, maksimal 25 halaman	Wajib	Halaman kontak, “tentang kami”, dan grosir selalu masuk anggaran
FR-18	Halaman kontak, “tentang kami”, dan grosir selalu diambil, dari tahap mana pun produknya berasal	Wajib	Toko Shopify pun memiliki halaman-halaman ini di data mentah bila tersedia

6.4 Ekstraksi

ID	Kebutuhan	Prioritas	Kriteria penerimaan
FR-19	Membaca JSON-LD, Microdata, OpenGraph, dan RDFa	Wajib	Setiap format punya fixture yang lulus tes
FR-20	Membaca state aplikasi di <code><script>(__NEXT_DATA__, __NUXT__, window.__INITIAL_STATE__)</code>	Wajib	Fixture situs Next.js atau Nuxt lulus tes
FR-21	Pemeriksaan konten per halaman untuk memutuskan render	Bersyarat	Ambang ditetapkan dari survei; keputusan tercatat per halaman
FR-22	Render dengan Camoufox dan tangkap XHR JSON, maksimal 10 halaman per toko	Bersyarat	Robots dan jeda berlaku; lokal <code>en-US</code> ; tes memakai renderer tiruan
FR-23	Ekstraksi LLM dengan skema Pydantic untuk toko yang masih nol produk	Bersyarat	Produk tanpa URL bukti yang valid dibuang; semua hasil bertanda <code>needs_review</code>
FR-24	Batas biaya LLM per run	Bersyarat	Run berhenti memanggil LLM saat batas tercapai dan mencatatnya di laporan

6.5 Penyimpanan dan pelaporan

ID	Kebutuhan	Prioritas	Kriteria penerimaan
FR-25	JSON mentah per domain sesuai spesifikasi bagian 7	Wajib	Setiap toko yang diambil punya satu berkas yang lolos validasi skema
FR-26	HTML lengkap setiap halaman disimpan terkompresi	Wajib	Berkas <code>.html.gz</code> dapat dibuka dan dirujuk dari JSON mentah
FR-27	Indeks keluaran dalam JSONL: satu objek per baris masukan	Wajib	Jumlah objek di indeks sama dengan jumlah baris masukan
FR-28	Laporan run	Wajib	Memuat jumlah per status, cakupan per sumber, daftar <code>no_products</code> dan <code>needs_review</code> , tahap yang dilewati, durasi, dan total token
FR-29	Status <code>no_products</code> untuk situs terbaca tanpa katalog	Wajib	Tidak ada toko berstatus <code>ok</code> dengan nol produk
FR-30	Pustaka setiap tahap dipilih melalui <code>config.yaml</code>	Sebaiknya	Mengganti backend LLM tidak memerlukan perubahan kode
FR-31	Adapter keluaran dipilih lewat konfigurasi; beberapa adapter dapat aktif sekaligus	Wajib	JSON + JSONL selalu tersedia; menambah adapter tidak mengubah alur
FR-32	Adapter keluaran Parquet, SQLite, dan PostgreSQL	Sebaiknya	Isi ketiganya sama dengan indeks JSONL pada run yang sama
FR-33	Ekspor CSV datar sebagai adapter opsional	Sebaiknya	Field bertingkat diratakan dengan nama bertitik, mis. <code>input.store_name</code>

7. Spesifikasi Data Mentah

“Mentah” berarti disimpan **persis seperti ditemukan**. Harga disimpan sebagai teks aslinya, mata uang sebagai kode atau simbol aslinya, dan objek sumber disimpan utuh. Yang ditambahkan bot hanyalah keterangan asal data.

7.1 Susunan berkas

```
data/
  raw/
    <domain>/
      store.json          # data mentah toko (bagian 7.2)
      pages/<hash>.html.gz # HTML lengkap setiap halaman
      feeds/<n>.json       # respons umpan apa adanya
      xhr/<hash>.json      # JSON yang ditangkap peramban
  out/
    <run>/index.jsonl      # satu objek per baris masukan
    <run>/products.parquet # opsional, adapter Parquet
    <run>/run-report.md    # laporan run
    <run>/manifest.json    # konfigurasi, versi, durasi, token
```

7.2 Isi store.json

```
{
  "schema_version": "1.0",
  "domain": "contoh-butik.com",
  "url": "https://contoh-butik.com",
  "input": [ { ...semua field masukan, apa pun formatnya... } ],
  "fetched_at": "2026-10-20T09:15:02Z",
  "status": "ok",
  "error": "",
  "platform": "woocommerce",
  "currency": { "value": "USD", "source": "feed" },
  "layers_tried": [
    { "layer": "feed", "result": "products", "count": 142, "ms": 4120 }
  ],
  "products": [
    {
      "title": "Cable Knit Cardigan",
      "price_raw": "9800",
      "currency_raw": "USD",
      "url": "https://contoh-butik.com/product/cable-knit",
      "source": "woocommerce_api",
      "evidence_url": "https://contoh-butik.com/wp-json/wc/store/v1/products",
      "needs_review": false,
      "raw": { ...objek sumber utuh... }
    }
  ],
  "pages": [
    { "url": ".../contact", "kind": "contact", "http_status": 200,
      "via": "http", "html_path": "pages/9f2c.html.gz", "text": "..." }
  ],
  "xhr": [ { "url": "...", "path": "xhr/a81b.json" } ],
  "llm": null
}
```

7.3 Status

Status	Arti
ok	Minimal satu produk mentah ditemukan
no_products	Situs terbaca, tetapi tidak ada tahap yang menemukan katalog
js_required	Memerlukan peramban yang belum terpasang atau belum dibangun
blocked	401, 403, 429, atau halaman tantangan; tidak ditembus
error	Kegagalan jaringan, galat HTTP lain, atau dilarang robots.txt
no_website, social_only	Dilewati pada tahap resolusi

Sertifikat TLS yang rusak tidak lagi menjadi status tersendiri, melainkan penanda `ssl_bypassed: true` di `store.json`, agar status utama tetap menjelaskan hasil pembacaan.

7.4 Indeks keluaran

Berkas `index.jsonl` berisi satu objek JSON per baris masukan: objek `input` dengan semua field masukan apa adanya, ditambah `domain`, `scrape_status`, `source_used`, `layers_tried`, `platform`, `currency`, `product_count`, `needs_review`, `ssl_bypassed`, `raw_path`, dan `fetched_at`. Indeks ini hanya menunjuk ke data mentah; ia tidak berisi hasil olahan. JSONL dipilih karena skemanya lentur (field masukan boleh berbeda antardaftar), dapat dibaca baris demi baris, dan langsung dapat dikueri oleh DuckDB atau pandas.

7.5 Format masukan dan keluaran dinamis

Masukan dan keluaran memakai pola adapter yang sama dengan tahap lain. Format dipilih lewat konfigurasi, sehingga tidak ada format yang wajib, termasuk CSV.

```
# config.yaml
input:
  source: data/prospects.jsonl # .json | .jsonl | .txt | .csv | tautan sheet
  url_field: website           # nama field yang berisi URL toko
output:
  dir: data/out
  writers: [jsonl]             # + parquet | sqlite | postgres | csv
  postgres_dsn: ${DATABASE_URL} # hanya bila writer postgres aktif
```

Arah	Adapter	Status
Masukan	JSON, JSONL, daftar URL (TXT), argumen CLI, CSV	Wajib
Masukan	Google Sheets	Sebaiknya
Keluaran	JSON per toko + indeks JSONL	Wajib, selalu aktif
Keluaran	Parquet, SQLite, PostgreSQL	Sebaiknya
Keluaran	CSV datar	Sebaiknya, opsional

8. Kebutuhan Nonfungsional

Aspek	Kebutuhan
Etika	<code>robots.txt</code> dipatuhi untuk HTTP dan peramban; jeda 1,5 detik per domain; hanya halaman publik; tanpa login; tanpa penembusan antibiot
Keandalan	Satu situs yang gagal tidak menghentikan run; setiap toko selalu mendapat status
Dapat dilanjutkan	Run ulang memakai cache respons berhasil dan hanya mencoba ulang yang gagal
Kinerja	Beberapa domain diproses paralel dengan jeda per domain tetap dijaga
Pengujian	Semua tes berjalan tanpa jaringan, memakai fixture HTTP, HTML render, dan respons LLM yang direkam
Ketertelusuran	Setiap produk punya tahap sumber dan URL bukti; manifest mencatat konfigurasi dan versi pustaka
Biaya	Token LLM dan waktu peramban dicatat; batas biaya per run dapat diatur
Keamanan	Kunci API di <code>.env</code> dan tidak pernah masuk repositori; berkas masukan di <code>data/</code> tidak masuk repositori; DSN basis data lewat variabel lingkungan
Portabilitas	Tanpa peramban atau kunci API, tahap lain tetap berjalan dan tahap yang dilewati dicatat
Pemeliharaan	Versi dependensi dikunci; peramban dan LLM sebagai dependensi opsional terpisah

9. Rencana Rilis

Tahap	Isi	Gerbang selesai
M0. Perbaikan v1	FR-05, FR-07, FR-10, FR-29; adapter masukan (FR-01, FR-01a); skema <code>store.json</code> , indeks JSONL (FR-25–FR-27, FR-31)	Semua tes lama lulus; tiap perbaikan punya tes baru
M1. Survei dan benchmark	Run baca-saja pada ± 41 situs non-Shopify; gold set 20 situs; benchmark pustaka	Matriks cakupan dan hasil benchmark ditinjau; memutuskan M3 dan M4
M2. Umpan dan ekstraksi	FR-12, FR-13, FR-15–FR-20, FR-26, FR-28	Fixture per pengurai; cakupan diukur ulang
M3. Render (bersyarat)	FR-21, FR-22	Hanya bila ≥ 5 situs calon mitra hanya terbaca dengan peramban
M4. LLM (bersyarat)	FR-23, FR-24	Hanya bila ≥ 5 situs calon mitra masih <code>no_products</code> setelah M3
M5. Rilis	Adapter keluaran tambahan (FR-32, FR-33) sesuai kebutuhan; run penuh; README; <code>CHANGELOG.md</code>	Semua metrik mutlak terpenuhi

10. Asumsi dan Dependensi

10.1 Asumsi

- Bot dijalankan sekali per daftar toko, sekitar 70 domain per run.
- Daftar masukan berasal dari Google Places, dalam format apa pun yang didukung adapter masukan, dan memiliki satu field berisi URL toko.
- Sebagian besar toko berada di Amerika Serikat, tetapi mata uang selalu dicatat.
- Data mentah akan diolah oleh tahap berikutnya yang terpisah dari PRD ini.

10.2 Dependensi

Dependensi	Diperlukan untuk	Keterangan
Python 3.11+	Semua	—
<code>extract</code> , <code>pydantic</code>	Ekstraksi dan skema	Dependensi inti
Camoufox	M3	Opsional; perlu <code>camoufox fetch</code> sekali
Kunci API Anthropic atau Ollama lokal	M4	Opsional; dipilih lewat benchmark
<code>pyarrow</code> , <code>psycopg</code>	Adapter keluaran	Opsional; hanya bila writer Parquet atau PostgreSQL aktif

11. Risiko dan Mitigasi

Risiko	Dampak	Mitigasi
Struktur situs atau umpan berubah	Pengurai gagal diam-diam	Fixture dari situs nyata; status <code>no_products</code> membuat kegagalan terlihat
LLM mengarang produk	Data mentah palsu	Aturan bukti URL; <code>needs_review</code> ; respons mentah disimpan
Harga dilokalkan	Mata uang salah	Tanpa <code>Accept-Language</code> ; lokal peramban <code>en-US</code> ; mata uang selalu dicatat
Lebih banyak situs memblokir	Cakupan turun	Dicatat sebagai <code>blocked</code> ; tinjau laju permintaan dan jenis IP sebelum hal lain
Biaya LLM membengkak	Anggaran terlampaui	Batas biaya per run (FR-24); LLM hanya untuk toko yang masih nol produk
Ukuran HTML besar	Penyimpanan membengkak	Kompresi gzip; batas halaman per toko

12. Pertanyaan Terbuka

No.	Pertanyaan	Pengaruhnya
1	Apakah bot nanti dijalankan berkala untuk memantau perubahan?	Bila ya, penyimpanan perlu basis data dan riwayat antarjalan
2	Siapa atau sistem apa yang akan memakai data mentah ini?	Menentukan adapter keluaran bawaan selain JSONL
3	Apakah HTML lengkap perlu disimpan untuk semua halaman?	Ukuran penyimpanan; usulan saat ini: ya, terkompresi
4	Pustaka final untuk tahap LLM dan render	Ditentukan oleh benchmark M1
5	Apakah ada wilayah di luar Amerika Serikat dalam waktu dekat?	Format telepon, bahasa halaman, dan mata uang yang perlu diuji

13. Glosarium

Istilah	Arti
Data mentah	Data yang disimpan persis seperti ditemukan, ditambah keterangan asal
Umpan produk (<i>feed</i>)	Alamat yang disediakan platform toko untuk daftar produk dalam format JSON
Data terstruktur	Data produk yang ditanam di HTML dalam format baku, mis. JSON-LD
XHR	Permintaan data yang dilakukan halaman di latar belakang setelah dimuat
Render	Membuka halaman dengan peramban sungguhan agar JavaScript berjalan
Gold set	Kumpulan situs yang jawabannya sudah diperiksa manual, untuk benchmark
URL bukti	Alamat halaman atau respons tempat sebuah produk ditemukan
<code>needs_review</code>	Penanda bahwa data perlu diperiksa manusia sebelum dipakai
Adapter	Komponen yang dapat ditukar untuk satu tugas, mis. membaca JSONL atau menulis ke PostgreSQL, dipilih lewat konfigurasi
JSONL	Format berkas dengan satu objek JSON per baris; lentur dan mudah diproses bertahap