

Cara Kerja Scrapebot

Layer apa saja yang dipakai, fungsi masing-masing, di mana hasilnya bisa menyematkan, dan di mana resource terbuang

Tanggal	9 Oktober 2026
Cakupan	Hanya yang sudah jadi di kode. Bagian bertanda BARU ada di branch feat/final-knitwear-list , sudah lolos semua tes, tetapi belum di-commit dan belum diverifikasi penuh di run nyata.
Sumber angka	Run 8 Oktober 2026 (808 toko, 80 menit, LLM mati) dan run uji 9 Oktober (dihentikan di toko ke-19 dari 70, LLM menyala).

1. Ringkasan

Scrapebot membaca setiap toko lewat **7 layer inti**, berurutan dari yang paling murah dan pasti ke yang paling mahal. Begitu satu layer menemukan produk, layer yang lebih mahal **tidak dijalankan**. Layer inti itu dibungkus tahap pendukung: sebelum run (cari toko, masukan, fetch yang sopan) dan sesudahnya (menilai jenis toko, menyimpan tabel, membuat daftar final, menulis laporan).


- **Yang paling berguna:** feed platform. Pada run 8 Oktober, 83% dari 209.542 produk datang dari feed Shopify, gratis dan tepat.
- **Yang paling boros:** browser render. Dicoba di 146 toko, hanya 6 yang menghasilkan produk (4%), dengan 398 halaman dibuka di browser.
- **Yang paling menyematkan:** status *blocked*. 376 toko tertulis diblokir, padahal 306 di antaranya toko Shopify yang hanya sedang membatasi IP kita, dan 3 lagi toko normal yang salah dibaca sebagai challenge.
- **Yang berbayar:** cari toko (discover) dan LLM. LLM kini menyala bawaan dengan batas US\$1 per run; pada uji 9 Oktober biayanya US\$0,019 untuk 18 panggilan.

2. Flowchart layer


Panah hijau **ya** berarti produk sudah ditemukan, jadi layer yang lebih mahal dilewati. Teks abu-abu di kanan adalah batas dan angka nyata tiap layer.

 murah dan pasti lebih banyak request lambat atau berbayar tahap pendukung BARU, belum di-commit

SEBELUM RUN



PER TOKO: 7 LAYER INTI (murah dan pasti dulu, mahal terakhir)



SETELAH TIAP TOKO DAN SETELAH SEMUA TOKO



3. Semua layer dalam satu tabel

Layer	Fungsi	Kapan jalan	Resource	Angka nyata
0 Cari toko	Menemukan toko rajut dari Google Places, Tavily dan agen LLM; hasilnya berkas tautan untuk run	Hanya jika diminta, sebelum run	Berbayar; ada batas request dan biaya (agen US\$2), plus cache	7 Okt: 14 toko, US\$0,07. Places dan Tavily belum pernah jalan (belum ada key)
Masukan & resolve	Mengambil URL dari teks atau berkas, satu baris per domain, mencatat yang dilewati	Selalu	Lokal, tanpa jaringan	8 Okt: 813 tautan = 808 diproses + 5 dilewati
Fondasi: Fetch	Satu-satunya pintu HTTP: robots.txt, jeda, retry, cache, deteksi challenge	Setiap request	Jeda 1,5 dtk per server; 6 toko paralel	Cache sudah 4,2 GB
1 Homepage	Membaca homepage, mengenali platform dan mata uang, mengumpulkan tautan	Selalu	1 request	376 blocked dan 25 error berhenti di sini
2 Feed platform	Mengambil katalog dari JSON resmi platform	Jika platform dikenali	Murah; maks 20 halaman feed	Shopify: 174.226 produk (83%)
3 Halaman prioritas	Mengambil kontak, about, wholesale, stockist, brands	Selalu, maks 8	Murah	4.205 kontak; 21 halaman wholesale/stockist
4 Temukan halaman	Sitemap produk, kalau tidak ada: crawl tautan 2 tingkat	Hanya jika belum ada produk	Request terbanyak; maks 25 halaman/toko	Sitemap 204 toko (42 berhasil), crawl 95 (16)
5 Data terstruktur	Membaca produk yang dideklarasikan halaman	Pada halaman layer 4	Gratis, tanpa request baru	jsonld 3.838, app_state 1.767, bigcommerce 1.521
6 Browser render	Membuka halaman di Camoufox untuk situs JavaScript	Hanya jika masih 0 produk	Paling lambat; maks 10 halaman	146 toko dicoba, 6 berhasil (4%)
7 LLM baca produk	Membaca teks halaman; produk wajib terbukti ada di halaman	Hanya jika masih 0 produk	Berbayar, ±US\$0,001/panggilan, batas US\$1	9 Okt: 6 situs custom terbaca (mis. helloboutique 67 produk)
Nilai jenis toko (BARU)	Multi-brand atau merek sendiri; mana produk yang benar-benar rajutan	Setiap toko yang terbaca	Gratis via vendor; LLM hanya jika tidak jelas dan ada rajutan	8 Okt: aturan vendor memutuskan 176 dari 267 toko
Tabel & ekspor	8 tabel mentah, ditulis ke format pilihan	Setelah semua toko	Disk	209.542 produk, 4.652 halaman
Daftar final (BARU)	Toko multi-brand yang menjual rajutan + produk rajutnya	Setelah semua toko	Ringan	8 Okt (simulasi): 171 toko, 21.156 produk rajut
Laporan	Rekonsiliasi, status, daftar final, biaya LLM, file	Paling akhir	Ringan	Selalu seimbang

4. Fungsi tiap layer

0 Cari toko (discover)

Mencari toko rajut sebelum run: Google Places (toko fisik), Tavily (web serta profil Instagram dan Facebook yang muncul di hasil pencarian) dan agen LLM dengan web search. Hasil dari semua sumber digabung menjadi satu baris per toko, lalu ditulis ke stores.csv yang bisa langsung dipakai run.

Tidak pernah membuka situs toko atau profil Instagram dan Facebook. Setiap sumber punya batas request, agen LLM punya batas biaya US\$2, dan jawaban disimpan di cache supaya pencarian ulang tidak membayar dua kali.

Masukan & resolve

Menerima teks bebas atau berkas (.txt, .csv, .tsv, .xlsx, .json, .jsonl, .parquet), mengambil URL-nya, lalu mengelompokkan per domain. Tautan produk menandai tokonya dan halamannya ikut diambil.

Tautan media sosial, marketplace, duplikat dan URL rusak tidak dibuang diam-diam: dicatat dengan alasannya, sehingga laporan selalu seimbang (masuk = diproses + dilewati).

Fondasi: Fetch yang sopan

Satu-satunya modul yang mengirim request HTTP. Mematuhi robots.txt, memberi jeda 1,5 detik per jaringan server (bukan per nama domain, karena ribuan toko Shopify berbagi satu edge), retry 2 kali untuk 429/5xx, dan cache untuk respons yang sukses saja.

Halaman challenge anti-bot (Cloudflare, DataDome, PerimeterX, ...) dicatat sebagai blocked dan tidak pernah diakali. Header Accept-Language tidak dikirim agar harga tidak dilokalkan.

1 Homepage + profil situs

Mengambil homepage, mengenali platform (Shopify, Wix, WooCommerce, ...) dan mata uang, lalu mengurutkan tautan: prioritas, koleksi, produk, lainnya.

Gagal di sini berarti toko selesai: blocked (challenge, 401, 403, 429) atau error.

2 Feed platform

Membaca katalog dari endpoint JSON resmi platform: Shopify /products.json, WooCommerce Store API, Squarespace, Lightspeed, Magento GraphQL, Big Cartel. Hasilnya tepat: judul, harga, vendor, tipe, tag.

Jika feed memberi produk, layer 4 sampai 7 dilewati. Maks 2.000 produk per toko.

3 Halaman prioritas

Mengambil halaman kontak, about, wholesale, stockist dan brands (maks 8), ditambah tautan dalam dari masukan. Selalu jalan, ada feed atau tidak, supaya kontak toko Shopify tidak terlewat.

Inilah sumber tabel contacts (email, telepon, Instagram, Facebook, TikTok, LinkedIn) dan halaman wholesale.

4 Temukan halaman

Untuk toko yang belum punya produk: membaca sitemap produk; jika tidak ada, menelusuri tautan homepage sampai 2 tingkat.

Total maks 25 halaman per toko, termasuk homepage dan halaman prioritas.

5 Data terstruktur

Membaca produk yang dideklarasikan halaman: JSON-LD, Microdata, RDFa, OpenGraph, state aplikasi JavaScript (Next.js, Wix) dan kartu produk BigCommerce.

Tidak ada request baru; hanya membaca halaman yang sudah diambil di layer 4.

6 Browser render (Camoufox)

Untuk toko yang masih 0 produk: membuka halaman di browser sungguhan supaya isi yang dibuat JavaScript muncul, dan menangkap JSON produk yang dimuat halaman.

Aturan robots.txt dan jeda sama dengan HTTP. Halaman challenge tetap dicatat blocked. Maks 10 halaman per toko; jika homepage bukan shell JavaScript, hanya 3 halaman dicoba.

7 LLM membaca produk

Untuk toko yang masih 0 produk setelah semua layer: model membaca teks maks 6 halaman (6.000 karakter per halaman) dan mengembalikan produk dalam skema tetap.

Aturan bukti: produk dibuang jika judul dan harganya tidak tertulis di halaman yang dikirim. Semua baris LLM ditandai needs_review. Ada batas biaya per run dan model cadangan.

Nilai jenis toko + rajutan ketat (BARU)

Rajutan ketat (knit_kind): dari judul dan tipe produk, bukan tag atau deskripsi. Jenis toko: tiga merek luar atau lebih di vendor produk, tanpa satu merek di atas 90%, berarti multi-brand. Nama toko sendiri dan vendor kosong seperti "Default Vendor" tidak dihitung.

Jika vendor tidak jelas dan toko menjual rajutan, LLM menilai dari halaman about, brands dan homepage. Jawaban dengan keyakinan di bawah 0,6 dibiarkan "belum jelas" dan dicantumkan di laporan untuk dicek manusia.

Tabel mentah + ekspor

Delapan tabel (runs, inputs, stores, products, pages, contacts, changes, llm_calls) ditulis per toko sebagai JSONL, lalu diubah ke format pilihan: JSON, JSONL, CSV, TSV, Excel, Parquet, SQLite, DuckDB.

Semua toko dan semua produk disimpan apa adanya (harga tetap price_raw). HTML tidak pernah diekspor; yang disimpan teks halaman.

Daftar final (BARU)

Toko yang terbaca (ok), multi-brand, dan punya minimal satu produk rajutan. final_stores berisi merek, jumlah rajutan, email, telepon, Instagram, Facebook, halaman wholesale; final_products hanya produk rajutnya.

Turunan dari tabel mentah, jadi kriteria bisa diubah tanpa scrape ulang. Ada di export/final/, menjadi unduhan pertama dan tab pertama di aplikasi web.

Laporan run

Rekonsiliasi, status toko, daftar final dan alasan toko lain tidak masuk, sumber produk, kontak, toko yang perlu dilihat, pemakaian dan biaya LLM, file yang ditulis.

Ditulis paling akhir; keberadaannya menandai run selesai.

Di luar layer scraping

Dua halaman aplikasi web bukan bagian dari alur di atas: **Traffic toko** membaca sesi di toko Shopify kita sendiri lewat Shopify Analytics (ADR 0009), dan **Deteksi** merangkum toko mana yang memblokir bot dari semua run. Deteksi ikut terdampak masalah status blocked di bagian 5.

5. Di mana hasilnya bisa menyesatkan

Diurutkan dari dampak terbesar. Semua sudah dibuktikan dengan data nyata; tidak ada yang diperbaiki di branch ini kecuali yang ditandai.

Masalah	Bukti	Dampak	Usulan
Rate limit IP kita ditulis sebagai blocked	306 dari 376 toko blocked (8 Okt) ada di edge Shopify 23.227.38.x, datang bergelombang; 20 sampel dibuka lagi 9 Okt: semua normal	Halaman Deteksi menyarankan toko-toko ini dibuang dari daftar berikutnya	Status terpisah rate_limited, jeda per jaringan, antre ulang otomatis
Halaman normal dibaca sebagai challenge Cloudflare	Cloudflare menyisipkan skrip /cdn-cgi/challenge-platform/ di halaman biasa; shopluxboutique, panachenaples, shadyandkatie: status 200, halaman utuh, tetap blocked	Toko yang di v1 terbaca kini hilang	Cek isi halaman, bukan hanya keberadaan skrip
Cache tidak pernah kedaluwarsa	Tidak ada batas umur di fetch.py; cache 4,2 GB	Run bulanan membaca data bulan lalu; deteksi perubahan tidak akan melihat perubahan harga	Batas umur cache, mis. 7 hari
Flag is_knitwear terlalu longgar	45.108 produk ditandai rajutan (8 Okt), termasuk kaos, celana, kaos kaki, lilin; aturan ketat memberi 23.185 pakaian + 1.458 aksesoris	knit_count dan summary.csv melebihi-lebihkan rajutan	Daftar final memakai aturan ketat (BARU); flag lama tetap sebagai sinyal mentah
no_products bercampur situs bukan toko	Daftar 8 Okt berisi vimeo.com, ticketmaster.com, npin.cdc.gov, situs berita	Cakupan non-Shopify terlihat 46%, padahal sebagian bukan toko	Status not_a_store, atau saring sebelum run
LLM bisa "menemukan produk" di situs bukan toko	texasranches.com (situs properti) memberi 2 produk (9 Okt)	Kecil: baris ditandai needs_review dan tidak masuk daftar final	Panggil LLM hanya untuk situs yang punya tanda toko
Laporan menyebut render "belum tersedia"	Daftar tahap yang belum ada masih mencantumkan render, padahal sudah jadi	Pembaca laporan salah paham	Sudah diperbaiki di branch ini

6. Di mana resource terbuang

Pemborosan	Bukti	Usulan
Browser render pada situs yang tidak punya katalog	146 toko dicoba, 6 berhasil (4%); 398 halaman dibuka; tiap halaman bisa sampai 36 detik	Render hanya jika homepage memang shell JavaScript atau halaman menunjukkan harga / tombol keranjang
Request ke edge Shopify tetap jalan setelah kena challenge	Gelombang blocked di run 8 Okt: 31, 64, 53, lalu turun, lalu 58, 64	Berhenti sementara per jaringan saat challenge pertama, lanjutkan toko lain dulu
Situs bukan toko dikunjungi penuh	Situs berita dan pemerintah tetap melewati 25 halaman, render, dan (kini) LLM	Saring daftar sebelum run
Cache menyimpan HTML mentah	4,2 GB di data/.cache	Batas umur dan pembersihan otomatis

Yang ternyata **bukan** pemborosan: halaman berjenis "other" (1.536 dari 4.652 halaman) menyumbang 1.895 produk lewat data terstruktur, dan LLM sendiri murah (sekitar US\$0,001 per panggilan).

7. Status

Bagian	Status
Cari toko, masukan, fetch, layer 1–7, tabel, 8 format ekspor, laporan, aplikasi web	Sudah jadi dan ada di main
Nilai jenis toko, rajutan ketat, daftar final, LLM menyala bawaan	BARU: di branch feat/final-knitwear-list, 516 tes Python + 23 tes web + 6 tes e2e lolos, belum di-commit, run verifikasi dihentikan di toko ke-19
Perbaikan blocked palsu, rate_limited, batas umur cache, status not_a_store	Belum dikerjakan (roadmap: isu 15, 16, 17)
Pengaturan wilayah, Google Sheets, PostgreSQL, deteksi perubahan	Belum dikerjakan (M5)